



(12) 发明专利申请

(10) 申请公布号 CN 120875055 A

(43) 申请公布日 2025. 10. 31

(21) 申请号 202511386128.0

G06F 16/335 (2019.01)

(22) 申请日 2025.09.26

(71) 申请人 吉奥时空信息技术股份有限公司

地址 430223 湖北省武汉市东湖开发区庙
山小区江夏大道武大科技园

(72) 发明人 刘健 付卓 吴龙 王敬佩

杨伊态 陈胜鹏

(74) 专利代理机构 武汉泰山北斗专利代理事务

所(特殊普通合伙) 42250

专利代理师 董佳佳

(51) Int. Cl.

G06N 5/04 (2023.01)

G06N 5/022 (2023.01)

G06N 3/006 (2023.01)

G06F 16/3329 (2025.01)

权利要求书4页 说明书13页 附图5页

(54) 发明名称

一种AI智能体的记忆系统及其更新方法、检索方法

(57) 摘要

本发明提供了一种AI智能体的记忆系统及其更新方法、检索方法,记忆系统包括时限查询缓存模块、短期记忆模块、中期记忆模块和长期记忆模块;时限查询缓存模块,用于存储短时间内的数据,短期记忆模块、中期记忆模块和长期记忆模块分别存储不同容量和不同表示方式的数据。本发明提取历史对话信息,以短、中、长期记忆进行存储,在用户问询时,根据问询内容召回相关的记忆内容,以增强提示词信息,提高智能体的复杂任务执行效果。

记忆系统框架

时限查询
缓存模块中期记忆
模块短期记忆
模块长期记忆
模块

1. 一种AI智能体的记忆系统,其特征在于,包括时限查询缓存模块、短期记忆模块、中期记忆模块和长期记忆模块;

所述时限查询缓存模块,用于以键值对的格式存储数据,所述键为问询,所述值为回答,并设置存储数据的有效时效;

所述短期记忆模块,用于存储短期记忆数据,所述短期记忆数据的存储格式为问答对,每一个问答对包括一个问询文本和一个回答文本,并设置最大存储的问答对数量;

所述中期记忆模块,用于存储中期记忆数据,所述中期记忆数据的存储格式为话题块,每一个话题块包括多个属性,多个所述属性包括话题ID、至少一个话题关键词、话题频率、话题最近检索时间、话题向量、话题对话信息,所述话题对话信息包括多组问答信息,每一组所述问答信息包括一个问答对向量和问答对文本,并设置最大存储的问答对数量;

所述长期记忆模块,用于存储长期记忆数据,所述长期记忆数据的存储格式为用户块,所述用户块包括多个属性,多个所述属性包括用户特点、用户ID和用户知识信息,所述用户知识信息包括多个知识块,每个知识块包括一个知识向量和一个知识具体信息,并设置最大存储的知识块。

2. 一种AI智能体的记忆系统的更新方法,其应用于权利要求1所述的AI智能体的记忆系统中,其特征在于,所述更新方法包括:

输入问答对,基于大模型对所述问答对进行质量检测;

若所述问答对为重复内容,则结束;否则,将输入的问答对以队列的形式存储在所述短期记忆模块中,对所述短期记忆模块进行更新;

当所述短期记忆模块中的问答对的数量超过最大容量时,将队列首部的问答对弹出,输出到所述中期记忆模块中,对所述中期记忆模块进行更新;

当所述中期记忆模块中的问答对超过最大容量时,计算出所述中期记忆模块中需要移出的话题块,并移出该话题块至所述长期记忆模块中,对所述长期记忆模块进行更新。

3. 根据权利要求2所述的更新方法,其特征在于,所述输入问答对,基于大模型对所述问答对进行质量检测,包括:

输入问答对,召回所述短期记忆模块中的所有的问答对;

基于输入的问答对和所述短期记忆模块中的所有的问答对,根据提示词模块构造提示词,所述提示词模版为:

【短期记忆】

{短期记忆}

【当前问题】

用户: {问询}

助手: {回答}

其中,{短期记忆}填入的是从所述短期记忆模块中召回的所有问答对,{问询}填入的是输入的问答对中的问询,{回答}填入的是输入的问答对中的回答;

将构造的提示词输入到大模型中,基于大模型输出所述问答对的质量检测结果,所述质量检测结果包括重复内容、无意义回复或其他;

当所述质量检测结果为重复内容,则结束;当所述质量检测结果为无意义回复时,将输入的所述问答对中的回答强制改为无意义回答,并输入所述短期记忆模块;当所述质量检

测结果为其他,则将输入的所述问答对输入所述短期记忆模块中。

4. 根据权利要求2所述的更新方法,其特征在于,当所述短期记忆模块中的问答对的数量超过最大容量时,将队列首部的问答对弹出,输出到所述中期记忆模块中,对所述中期记忆模块进行更新,包括:

将问答对输入向量嵌入模型中,得到对应的问答对向量;

计算所述问答对向量与所述中期记忆模块中每一个话题块的话题向量之间的相似度,得到多个相似度;

若所有的相似度均小于预设相似度阈值,则基于问答对在所述中期记忆模块中新建一个话题块;

否则,获取多个相似度中的最大相似度,将所述问答对和所述问答对向量加入所述最大相似度对应的话题块的话题对话信息中,并更新此话题块的属性。

5. 根据权利要求4所述的更新方法,其特征在于,所述若所有的相似度均小于预设相似度阈值,则基于问答对在所述中期记忆模块中新建一个话题块,包括:

基于哈希函数随机创建新建话题块的话题ID;

将问答对输入大模型,基于大模型输出多个话题关键词;

话题频率设定为1;

设置话题最近检索时间为当下时间;

将多个话题关键词和问答对拼接,输入向量嵌入模型中,生成话题向量;

将问答对输入向量嵌入模型中,生成问答对向量,所述问答对向量和问答对组成话题对话信息;

将话题ID、话题关键词、话题频率、话题最近检索时间、话题向量和话题对话信息作为话题块的多个属性;

将所述问答对和所述问答对向量加入所述最大相似度对应的话题块的话题对话信息中,并更新此话题块的属性,包括:

将问答对输入大模型,基于大模型输出多个新话题关键词,将话题块的话题关键词更新为新话题关键词,将话题块的话题频率增加1,将话题块的话题最近检索时间更新为当下时间;

将新话题关键词和话题块中的所有问答对拼接,输入向量嵌入模型中,生成新话题向量,并更新话题块中的话题向量。

6. 根据权利要求2所述的更新方法,其特征在于,所述计算出所述中期记忆模块中需要移出的话题块,包括:

计算所述中期记忆模块中的每一个话题块的信息有效值,所述信息有效值最低的话题块为需要移出的话题块;

其中,计算所述中期记忆模块中的每一个话题块的信息有效值,包括:

$$\text{value} = a * \text{话题频率} + b * (\text{当下时间} - \text{话题最近检索时间}) + c * (\text{话题块中问答对数量} / \text{中期记忆模块中的总问答对数量});$$

其中,a,b,c为预设系数。

7. 根据权利要求2所述的更新方法,其特征在于,所述移出该话题块至所述长期记忆模块中,对所述长期记忆模块进行更新,包括:

提取该话题块的话题对话信息中的所有问答对,将所有问答对输入大模型中,基于大模型总结出用户特点和知识具体信息;

根据总结出的用户特点更新所述长期记忆模块中的用户特点属性,将总结出的知识具体信息输入向量嵌入模型中,得到对应的知识向量;

将知识具体信息和对应的知识向量作为一个知识元素,插入用户知识信息的队列的队尾。

8. 一种AI智能体的记忆系统的检索方法,其应用于权利要求1所述的AI智能体的记忆系统中,其特征在于,所述检索方法包括:

将用户问询文本作为键,在所述时限查询缓存模块中检索,如果命中,则输出对应的回答文本,并更新所述时限查询缓存模块中相应键值对的有效时间;

如果在所述时限查询缓存模块中未命中,则基于所述用户问询文本分别在所述短期记忆模块、所述中期记忆模块和所述长期记忆模块中进行检索,将得到的短期记忆检索结果、中期记忆检索结果和长期记忆检索结果进行拼接输出,得到检索结果,且根据检索结果更新所述时限查询缓存模块中的键值对。

9. 根据权利要求8所述的检索方法,其特征在于,所述基于所述用户问询文本分别在所述短期记忆模块、所述中期记忆模块和所述长期记忆模块中进行检索,包括:

将用户问询文本输入所述短期记忆模块,所述短期记忆模块直接返回所有问答对最为短期记忆检索结果;

将用户问询文本输入所述中期记忆模块进行检索,分别输出向量召回结果和关键词召回结果,根据所述向量召回结果和所述关键词召回结果,确定中期记忆检索结果;

将用户问询文本输入向量嵌入模型中,得到问询向量,计算所述问询向量与所述长期记忆模块中的用户块的每一个知识向量之间的余弦相似度,返回与所述问询向量的相似度最大的知识向量,以及从所述长期记忆模块中直接返回用户特点信息,将返回的用户特点信息和知识信息作为长期记忆检索结果。

10. 根据权利要求9所述的检索方法,其特征在于,所述将用户问询文本输入所述中期记忆模块进行检索,分别输出向量召回结果和关键词召回结果,根据所述向量召回结果和所述关键词召回结果,确定中期记忆检索结果,包括:

将用户问询文本输入向量嵌入模型,得到问询向量,从所述中期记忆模块中召回所有话题块的话题向量;

计算所述问询向量与每一个话题块的话题向量之间的余弦相似度,根据所述相似数值,对每一个话题块从高到低进行排序,作为向量召回排序;

将用户问询文本与所述中期记忆模块中的每一个话题块的多个关键词进行对比,如果关键词包含在用户问询文本中,则关键词命中,统计每一个话题块中关键词的命中数量;根据每一个话题块中的关键词的命中数量,从多到少对每一个话题块进行排序,作为关键词召回排序;

根据所述向量召回排序和所述关键词召回排序,计算每一个话题块的融合分数:

$$rrf\text{-}score(d \in D) = \sum_{r \in R} \frac{1}{k + w_r \cdot r(d)};$$

其中,rrf-score表示话题块的融合分数,r(d)表示话题块d在第r种召回中的排名,r=

1,2,k为设定数值, w_r 是第r种召回的权重;

将融合分数最高的话题块作为检索命中的话题块,且返回话题块中的话题对话信息,作为中期记忆检索结果。

一种AI智能体的记忆系统及其更新方法、检索方法

技术领域

[0001] 本发明涉及人工智能技术领域,更具体地,涉及一种AI智能体的记忆系统及其更新方法、检索方法。

背景技术

[0002] 随着人工智能技术的快速发展,AI助手或智能体(以下统一称为智能体)在城市治理与地理测绘领域的应用需求日益增长。在长期会话情景下,大模型的词元(token)最大处理长度和提示词的信息质量是制约复杂任务高效执行的关键瓶颈。如用户第一次问询助手某地区的人口分布情况,助手给出了答案。当用户在第100次对话的时候,再次问询人口分布与房屋分布比的时候,已有的智能体就很难利用到第一次问询的回复。因此如何保留历史会话中的有用信息,并将其作为智能体的记忆是提高其性能的要害。

[0003] 已有的长记忆方法主要分为3种,第一种是基于知识组织的长记忆方法。这类方法主要侧重将对话内容组织成易于管理和检索的格式。但这类方法往往独立工作,容易忽略检索和更新记忆等环节的协同,对于多噪音和复杂多轮任务的问答场景效果较差,比如基于RAG或知识图谱的增强记忆方法,其将问答信息存入外加的RAG系统,检索记忆时则根据问询从RAG系统中查询相关记忆,并返回。

[0004] 第二种是基于架构驱动的长记忆方法。这类方法通过借鉴计算机操作系统或人脑记忆的工作机制,采用分层结构保存和处理记忆。如MemGPT,其采用类似操作系统的分层结构,动态处理记忆。

[0005] 第三种是基于检索的长记忆方法。这类方法主要聚焦于优化记忆检索算法来提高用户问询相关召回准确率。比如基于向量数据库的长记忆方法,将所有问答信息转成语义向量,存到向量数据库。查询时根据查询的语义返回语义最相似的记忆内容。

[0006] 但已有的长记忆方法工作中都忽略了记忆更新的质量。比如:当用户多次输入相似问题时(如连续问智能体20次同一个问题),记忆方法应该选择性的只保留一个记忆;或者输入的内容具有明显异常时(如用户问公司的产值情况,智能体无法从知识库中检索到相关内容,然后随意给个错误数字),记忆方法应该忽略这条记忆。

[0007] 当这两类问答增加时,已有的长记忆方法会使得记忆质量严重下降,甚至混淆事实。

发明内容

[0008] 本发明针对现有技术中存在的技术问题,提供一种AI智能体的记忆系统及其更新方法、检索方法,旨在提高智能体的长记忆质量和记忆检索速度,从而提高智能体处理复杂任务的能力。

[0009] 根据本发明的第一方面,提供了一种AI智能体的记忆系统,包括时限查询缓存模块、短期记忆模块、中期记忆模块和长期记忆模块;

[0010] 所述时限查询缓存模块,用于以键值对的格式存储数据,所述键为问询,所述值为

回答,并设置存储数据的有效时效;

[0011] 所述短期记忆模块,用于存储短期记忆数据,所述短期记忆数据的存储格式为问答对,每一个问答对包括一个问询文本和一个回答文本,并设置最大存储的问答对数量;

[0012] 所述中期记忆模块,用于存储中期记忆数据,所述中期记忆数据的存储格式为话题块,每一个话题块包括多个属性,多个所述属性包括话题ID、至少一个话题关键词、话题频率、话题最近检索时间、话题向量、话题对话信息,所述话题对话信息包括多组问答信息,每一组所述问答信息包括一个问答对向量和问答对文本,并设置最大存储的问答对数量;

[0013] 所述长期记忆模块,用于存储长期记忆数据,所述长期记忆数据的存储格式为用户块,所述用户块包括多个属性,多个所述属性包括用户特点、用户ID和用户知识信息,所述用户知识信息包括多个知识块,每个知识块包括一个知识向量和一个知识具体信息,并设置最大存储的知识块。

[0014] 根据本发明的第二方面,提供一种AI智能体的记忆系统的更新方法,包括:

[0015] 输入问答对,基于大模型对所述问答对进行质量检测;

[0016] 所述问答对为重复内容,则结束;否则,将输入的问答对一队列的形式存储在所述短期记忆模块中,对所述短期记忆模块进行更新;

[0017] 当所述短期记忆模块中的问答对的数量超过最大容量时,将队列首部的问答对弹出,输出到所述中期记忆模块中,对所述中期记忆模块进行更新;

[0018] 当所述中期记忆模块中的问答对超过最大容量时,计算出所述中期记忆模块中需要移出的话题块,并移出该话题块至所述长期记忆模块中,对所述长期记忆模块进行更新。

[0019] 根据本发明的第三方面,提供了一种AI智能体的记忆系统的检索方法,包括:

[0020] 将用户问询文本作为键,在所述时限查询缓存模块中检索,如果命中,则输出对应的回答文本,并更新所述时限查询缓存模块中相应的键值对的有效时间;

[0021] 如果在所述时限查询缓存模块中未命中,则基于所述用户问询文本分别在所述短期记忆模块、所述中期记忆模块和所述长期记忆模块中进行检索,将得到的短期记忆检索结果、中期记忆检索结果和长期记忆检索结果进行拼接输出,得到检索结果,且根据检索结果更新所述时限查询缓存模块中的键值对。

[0022] 本发明提供的一种AI智能体的记忆系统及其更新方法、检索方法,记忆系统设计了时限查询缓存模块、短期记忆模块、中期记忆模块和长期记忆模块;时限查询缓存模块,用于存储短时间内的数据,

[0023] 短期记忆模块、中期记忆模块和长期记忆模块分别存储不同容量和不同表示方式的数据。本发明提取历史对话信息,以短、中、长期记忆进行存储,在用户问询时,根据问询内容召回相关的记忆内容,以增强提示词信息,提高智能体的复杂任务执行效果。

附图说明

[0024] 图1为本发明一个实施例提供的一种AI智能体的记忆系统的框架示意图;

[0025] 图2为本发明一个实施例的时限查询缓存模块的数据存储格式示意图;

[0026] 图3为本发明一个实施例的短期记忆模块的数据存储格式示意图;

[0027] 图4为本发明一个实施例的中期记忆模块的数据存储格式的示意图;

[0028] 图5为本发明一个实施例的长期记忆模块的数据存储格式的示意图;

- [0029] 图6为本发明一个实施例的AI智能体的记忆系统的更新方法的流程图；
- [0030] 图7为本发明一个实施例的AI智能体的记忆系统的更新方法的整体流程图；
- [0031] 图8为本发明一个实施例的中期记忆模块进行更新的流程示意图；
- [0032] 图9为本发明一个实施例提供的一种AI智能体的记忆系统的检索方法流程图；
- [0033] 图10为本发明一个实施例的记忆系统的检索方法主要流程图。

具体实施方式

[0034] 为使本发明实施例的目的、技术方案和优点更加清楚,下面将结合本发明实施例中的附图,对本发明实施例中的技术方案进行清楚、完整地描述,显然,所描述的实施例是本发明一部分实施例,而不是全部的实施例。基于本发明中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于本发明保护的范围。另外,本发明提供的各个实施例或单个实施例中的技术特征可以相互任意结合,以形成可行的技术方案,这种结合不受步骤先后次序和/或结构组成模式的约束,但是必须是以本领域普通技术人员能够实现为基础,当技术方案的结合出现相互矛盾或无法实现时,应当认为这种技术方案的结合不存在,也不在本发明要求的保护范围之内。

[0035] 参见图1,图1示出了本发明一个实施例提供的一种AI智能体的记忆系统的框架示意图,AI智能体的记忆系统包括时限查询缓存模块、短期记忆模块、中期记忆模块和长期记忆模块。

[0036] 所述时限查询缓存模块,用于以键值对的格式存储数据,所述键为问询,所述值为回答,并设置存储数据的有效时效;

[0037] 所述短期记忆模块,用于存储短期记忆数据,所述短期记忆数据的存储格式为问答对,每一个问答对包括一个问询文本和一个回答文本,并设置最大存储的问答对数量;

[0038] 所述中期记忆模块,用于存储中期记忆数据,所述中期记忆数据的存储格式为话题块,每一个话题块包括多个属性,多个所述属性包括话题ID、至少一个话题关键词、话题频率、话题最近检索时间、话题向量、话题对话信息,所述话题对话信息包括多组问答信息,每一组所述问答信息包括一个问答对向量和问答对文本,并设置最大存储的问答对数量;

[0039] 所述长期记忆模块,用于存储长期记忆数据,所述长期记忆数据的存储格式为用户块,所述用户块包括多个属性,多个所述属性包括用户特点、用户ID和用户知识信息,所述用户知识信息包括多个知识块,每个知识块包括一个知识向量和一个知识具体信息,并设置最大存储的知识块。

[0040] 其中,参见图2,为时限查询模块的数据存储格式示意图,时限查询缓存模块提供插入数据和查找数据的接口,并以键值对的方式保存数据。在插入时,数据要以键值对的方式插入,并设置时效。如:

[0041] 插入:{你好:请问有什么可以帮您},时效:1小时

[0042] “您好”是键,“请问有什么可以帮您”是值,此键值对在1小时内有效,1小时后自动删除。

[0043] 在查询时,输入查询键,如果缓存中存有此键,则返回对应的值,否则返回空值。如:

[0044] 查询“你好”,1小时内,返回“请问有什么可以帮您”;1小时后则返回空值。

[0045] 查询“我好”,则返回空值。

[0046] 参见图3,为短期记忆模块的数据存储格式示意图,短期记忆模块用于存储短期记忆。存储的格式为问答对,每个问答对包含一个问询文本和一个回答文本。如:

[0047] 问询文本:你好

[0048] 回答文本:请问有什么可以帮您

[0049] 短期记忆模块有最大存储限制。如设置为10,则短期记忆最多可存储10个问答对。

[0050] 参见图4,为中期记忆模块的数据存储格式示意图,中期记忆模块用于存储中期记忆。存储的格式为话题块,每个话题块包含如下几个属性:

[0051] 话题ID:话题块的唯一标识符

[0052] 话题关键词:能够概括此话题的关键词,可以是多个

[0053] 话题频率:话题被检索的频繁程度

[0054] 话题最近检索时间:话题最近一次被检索或创建的时间,用于计算时间衰退值。

[0055] 话题向量:话题的语义编码

[0056] 话题对话信息:每个话题对话信息包含多组问答信息。每个问答信息包含一个问答对向量和问答对文本。

[0057] 如:

[0058] 话题块1:

[0059] {话题ID:9527;

[0060] 话题关键词:问候,心情,不开心;

[0061] 话题频率:1;

[0062] 话题最近检索时间:2025-08-21

[0063] 话题向量:[0.12, 0.11, 0.95, ..., 0.88]

[0064] 话题对话信息:

[0065] [

[0066] 问答信息1:

[0067] {问答向量:[0.12, 0.11, 0.95, ..., 0.87]

[0068] 问答对:[“你好”,“请问有什么可以帮您”]}

[0069] 问答信息2:

[0070] {问答向量:[0.13, 0.11, 0.95, ..., 0.87]

[0071] 问答对:[“不好”,“不好也要开心呀”]}

[0072]]

[0073] }

[0074] 中期记忆模块有最大存储限制。如设置为2000,则中期记忆最多可存储2000个问答对。

[0075] 参见图5,为长期记忆模块的数据存储格式示意图,长期记忆模块用于存储长期记忆。存储的格式为用户块,每个用户块包含如下几个属性:

[0076] 用户特点:根据用户历史对话概括出的用户偏好

[0077] 用户ID:用户的唯一标识符

[0078] 用户知识信息:用户知识信息包含多组知识块,每个知识块包含一个知识向量和

知识具体信息。存储方式为队列,添加在队尾添加,删除从队首删除。

[0079] 如:

[0080] 用户块1:

[0081] {用户ID:7295

[0082] 用户特点:对城市治理感兴趣

[0083] 用户知识信息:

[0084] [

[0085] 知识块1:

[0086] {知识向量:[0.13, 0.11, 0.96, ..., 0.87]

[0087] 知识具体信息:用户曾经和助手问好}

[0088] {知识向量:[0.13, 0.12, 0.95, ..., 0.87]

[0089] 知识具体信息:用户查询到人口分布,助手返回数据地址:ABC}

[0090]]

[0091] }

[0092] 长期记忆模块有最大存储限制。如设置为2000,则长期记忆最多可存储2000个知识块。

[0093] 参见图6,示出了本发明一个实施例提供的一种AI智能体的记忆系统的更新方法,可同时参见图6和图7,该更新方法主要包括如下步骤:

[0094] 步骤1,输入问答对,基于大模型对所述问答对进行质量检测。

[0095] 可理解的是,当向记忆系统输入一个问答对时,首先对输入的问答对进行质量检测。根据质量检测结果确定是否对记忆系统进行更新。

[0096] 具体对输入的问答对进行质量检测的方法为:

[0097] 输入问询-回答块,召回所述短期记忆模块中的所有的问答对,基于输入的问答对和短期记忆模块中的所有的问答对,根据提示词模块构造提示词输入到大语言模型,让大模型判断此问答对是重复内容、无意义回复还是其他。如果是重复内容,则不加入记忆模块,直接结束流程;如果是无意义回复,则将问询回答对中的回答强制改为:无意义回答;如果是其他,则将问询回答对原样输入至短期记忆。

[0098] 其中,比如,短期记忆模块中保存的问答对有2个:

[0099] 问答对1:[你好][请问有什么可以帮您]

[0100] 回答对2:[不好][不要也要开心啊]

[0101] **【短期记忆】**

[0102] {短期记忆}

[0103] **【当前问题】**

[0104] 用户:{询问}

[0105] 助手:{回答}

[0106] 其中,{短期记忆}填入的是从所述短期记忆模块中召回的所有问答对,{询问}填入的是输入的问答对中的问询,{回答}填入的是输入的问答对中的回答。

[0107] 大模型的提示模板可表示为:

[0108] **【角色】**你是一个具备自我审查能力的AI助手,专注于提供基于知识库的准确信

息。

[0109] 【任务】根据用户问题生成回答时,必须严格遵循以下规则:

[0110] 1. 知识库验证:如果回答内容无法通过你的知识库验证(如涉及实时数据、未收录事件或明确超出训练范围),请直接输出:回复结果:无意义回答。

[0111] 2. 重复检测:类型1:若当前问询与回答与本次短期记忆中的任意历史中的问询与回答含义基本都完全一致,请输出:回复结果:重复问询。

[0112] 3. 无意义回答:如果回答内容与问题无关、无法回答或与问题的上下文不相关,请直接输出:回复结果:无意义回答

[0113] 4. 其他情况:若以上规则均不适用,直接输出当前回答。

[0114] 5. 重复检测:类型2:当短期记忆中有一个问答对与当前问答对为:

[0115] 1. 用户的问询基本一致

[0116] 2. 短期记忆中的回答为无意义回答,而当前回答根据以上规则也归为无意义回答

[0117] 请输出:回复结果:重复问询。

[0118] 大模型的【执行流程】包括:

[0119] 1. 生成初步回答

[0120] 2. 检查回答是否包含“无法验证”、“不确定”、“知识库未收录”等否定性表述

[0121] 3. 比对历史回答库检测重复

[0122] 4. 根据规则决定最终输出

[0123] 一个具体的例子为:输入新的问询问答对:

[0124] 询问:不好

[0125] 回答:即使不好,那也要开心呀

[0126] 将短期记忆替换提示词模版中的{短期记忆},询问替换{询问},回答替换{回答},然后输入大模型中。

[0127] 如果大模型输出“重复问询”,则结束流程。

[0128] 如果大模型输出“无意义回答”,则将问询回答对改为[不好][无意义回答],输出到短期记忆。

[0129] 如果大模型输出其他的回答,则直接将问询回答对输出到短期记忆模块。

[0130] 步骤2,所述问答对为重复内容,则结束;否则,将输入的问答对一队列的形式存储在所述短期记忆模块中,对所述短期记忆模块进行更新。

[0131] 可理解的是,当对输入的问答对(问答对)的质量检测结果为重复内容,则结束,不对记忆模块进行更新。当输入的问答对的质量检测结果为无意义回答或其他是,对记忆模块进行更新。先基于输入的问答对对短期记忆模块进行更新。具体的,输入的问询回答对,以队列的形式存储在短期记忆模块中。每往短期记忆模块中加入一个问答对,就在队列末尾加入问答对。如果加入后大于最大容量,则将队列首个问答对弹出,输出到中期记忆模块,用于更新中期记忆。

[0132] 步骤3,当所述短期记忆模块中的问答对的数量超过最大容量时,将队列首部的问答对弹出,输出到所述中期记忆模块中,对所述中期记忆模块进行更新。

[0133] 参见图8,示出了对中期记忆模块进行更新的流程示意图。在本发明的一些实施例

中,对中期记忆模块进行更新,包括:

[0134] 将问答对输入向量嵌入模型中,得到对应的问答对向量;

[0135] 计算所述问答对向量与所述中期记忆模块中每一个话题块的话题向量之间的相似度,得到多个相似度;

[0136] 若所有的相似度均小于预设相似度阈值,则基于问答对在所述中期记忆模块中新建一个话题块;

[0137] 否则,获取多个相似度中的最大相似度,将所述问答对和所述问答对向量加入所述最大相似度对应的话题块的话题对话信息中,并更新此话题块的属性。

[0138] 具体的,对中期记忆模块进行更新的具体过程为:

[0139] 输入问答对,将问答对输入向量嵌入模型,得到对应的问答对向量。将问答对向量与中期记忆模块中每个话题块的话题向量进行比较,比较方式为余弦相似度计算。如果计算得到的所有相似度都小于预设相似度阈值,则新建一个话题块。如果计算得到的最高相似度比阈值大,则将问答对向量和问答对加入此话题块的话题块的话题对话信息中,并更新此话题块的属性。加入新的对话信息后,如果总的对话信息大于设定的最大存储限制,则计算出需要移出的话题块,并将移出的话题块输出给长期记忆模块。预设相似度阈值根据场景人为设置,如设置为0.6。

[0140] 其中,余弦相似度的计算公式为:

[0141] $\text{similarity} = (\text{A} \cdot \text{B}) / (||\text{A}|| * ||\text{B}||)$;

[0142] 其中A和B是两个向量,dot表示向量的点积, $||\text{A}||$ 和 $||\text{B}||$ 分别表示向量A和B的模长。

[0143] 如:现有

[0144] 问答对1:[你好][请问有什么可以帮您],问答对1的向量:[0.6, 0.4]

[0145] 话题块1向量:[0.1,0.9]

[0146] 话题块2向量:[0.4,0.6]

[0147] 问答对1与话题块1的相似度为:0.92

[0148] 问答对1与话题块2的相似度为:0.77

[0149] 如果相似阈值为0.9,则将问答对1加入话题块1中;如果相似阈值为0.95,则新开一个话题块3,将问答对1加入话题块3。

[0150] 其中,如果是向中期记忆模块中中间话题块时,对中期记忆模块进行更新的方式为:

[0151] 当问答对加入中期记忆中为新建话题块时,话题块的多个属性的生成方法包括:

[0152] 基于哈希函数随机创建新建话题块的话题ID;

[0153] 将问答对输入大模型,基于大模型输出多个话题关键词;

[0154] 话题频率设定为1;

[0155] 设置话题最近检索时间为当下时间;

[0156] 将多个话题关键词和问答对拼接,输入向量嵌入模型中,生成话题向量;

[0157] 将问答对输入向量嵌入模型中,生成问答对向量,所述问答对向量和问答对组成话题对话信息。

[0158] 如:插入问答对[不好][不要也要开心啊],

- [0159] 新建话题块3,属性设置为:
- [0160] 话题块3:
- [0161] {话题ID:9527;
- [0162] 话题关键词:心情,不开心;
- [0163] 话题频率:1;
- [0164] 话题最近检索时间:2025-08-21
- [0165] 话题向量:[0.12, 0.11, 0.95, ..., 0.88]
- [0166] 话题对话信息:
- [0167] [
- [0168] 问答信息1:
- [0169] {问答向量:[0.13, 0.11, 0.95, ..., 0.87]
- [0170] 问答对:["不好", "不好也要开心呀"]}
- [0171] 对于中期记忆模块中已有话题块的更新的方式为:
- [0172] 当问答对加入中期记忆中已有话题块时,生成话题块的新的属性,具体的属性生成方法包括:
- [0173] 将问答对输入大模型,基于大模型输出多个新话题关键词,将话题块的话题关键词更新为新话题关键词,将话题块的话题频率增加1,将话题块的话题最近检索时间更新为当下时间;
- [0174] 将新话题关键词和话题块中的所有问答对拼接,输入向量嵌入模型中,生成新话题向量,并更新话题块中的话题向量。
- [0175] 如:插入问答对[不好][不要也要开心啊],
- [0176] 插入话题块1,属性设置为:
- [0177] 话题块3:
- [0178] {话题ID:9527;
- [0179] 话题关键词:问候,心情,不开心; #重新生成
- [0180] 话题频率:211; #从210增加1
- [0181] 话题最近检索时间:2025-08-21 #刷新为相当时间
- [0182] #重新生成话题向量
- [0183] 话题向量:[0.12, 0.11, 0.95, ..., 0.88]
- [0184] 话题对话信息:
- [0185] [
- [0186] 问答信息1:
- [0187] {问答向量:[0.12, 0.11, 0.95, ..., 0.87]
- [0188] 问答对:["你好", "请问有什么可以帮您"]}
- [0189] 问答信息2:
- [0190] {问答向量:[0.13, 0.11, 0.95, ..., 0.87]
- [0191] 问答对:["不好", "不好也要开心呀"]}
- [0192]]
- [0193] 其中,生成关键词的提示词为:

- [0194] 从以下文本中提取3-5个最重要的关键词。请着重注意动词、形容词和名词：
- [0195] {话题文本}
- [0196] 关键词：
- [0197] 关键词生成的方式是将此话题块中的所有问答对连接到一起，并替换提示词中的{话题文本}，输入大模型，让大模型总结出话题的关键词。
- [0198] 步骤4，当所述中期记忆模块中的问答对超过最大容量时，计算出所述中期记忆模块中需要移出的话题块，并移出该话题块至所述长期记忆模块中，对所述长期记忆模块进行更新。
- [0199] 可理解的是，当中期记忆模块中的话题量超过最大容量时，需要计算中期记忆模块中需要移除的话题块。
- [0200] 具体的，当中期记忆中的对话信息超过设定的最大存储限制时，则需要移出一个对话块。移出的方式为通过计算每个话题块的信息有效值，计算公式为：
- [0201] $value = a * \text{话题频率} + b * (\text{当下时间} - \text{话题最近检索时间}) + c * (\text{话题块中间答对数量} / \text{中期记忆模块中的总问答对数量})$ 。
- [0202] 其中a,b,c是参数，人为设置，当下时间和话题检索时间都以天为单位。
- [0203] 计算出每个话题块的信息有效值后，将信息有效值最低的话题块移出中期记忆模块，输入长期记忆模块，对长期记忆模块进行更新。
- [0204] 比如，中期记忆模块中有2个话题块，
- [0205] 话题块1：{问答对：4个，频率：4，话题最近检索时间：2025-8-21}
- [0206] 话题块2：{问答对：3个，频率：2，话题最近检索时间：2025-8-20}
- [0207] 当前时间：2025-8-25
- [0208] 其中a设置为0.5，b设置为-0.3，c设置为0.2
- [0209] 则话题块1的信息有效值为： $0.5 * 4 - 0.3 * 4 + 0.2 * 4 = 1.6$
- [0210] 话题块2的信息有效值为： $0.5 * 2 - 0.3 * 5 + 0.2 * 4 = 0.75$
- [0211] 话题块2的值最低，因此将话题块2移出中期记忆模块，输入长期记忆模块。
- [0212] 其中，对长期记忆模块进行更新的方法为：
- [0213] 提取该话题块的话题对话信息中的所有问答对，将所有问答对输入大模型中，基于大模型总结出用户特点和知识具体信息；
- [0214] 根据总结出的用户特点更新所述长期记忆模块中的用户特点属性，将总结出的知识具体信息输入向量嵌入模型中，得到对应的知识向量；
- [0215] 将知识具体信息和对应的知识向量作为一个知识元素，插入用户知识信息的队列的队尾。
- [0216] 比如，输入话题块
- [0217] {话题ID:9527；
- [0218] 话题关键词:问候,心情,不开心；#重新生成
- [0219] 话题频率:211；#从210增加1
- [0220] 话题最近检索时间:2025-08-21 #刷新为相当时间
- [0221] #重新生成话题向量
- [0222] 话题向量:[0.12, 0.11, 0.95, ..., 0.88]

[0223] 话题对话信息:

[0224] [

[0225] 问答信息1:

[0226] {问答向量:[0.12, 0.11, 0.95, ..., 0.87]}

[0227] 问答对:[“你好”,“请问有什么可以帮您”]}

[0228] 问答信息2:

[0229] {问答向量:[0.13, 0.11, 0.95, ..., 0.87]}

[0230] 问答对:[“不好”,“不好也要开心呀”]}

[0231]]

[0232] 总结知识具体信息和用户特点的提示词为:

[0233] 你是一位用户资料合并与更新专家。请将新信息整合到旧资料中,保持一致性并提升对用户的整体理解,并从以下最新用户-AI对话中提取用户对话知识。

[0234] 旧用户特点:

[0235] {用户特点}

[0236] 最新用户-AI对话:

[0237] {对话信息}

[0238] **【用户对话知识】**

[0239] 提取用户个人信息(使用最简短短语表达):

[0240] - [简要事实]: [最小化上下文]

[0241] - [简要事实]: [最小化上下文]

[0242] - (若无对话知识则写“None”)

[0243] **【用户特点】**

[0244] - [偏好领域]: [偏好强度]

[0245] 将用户块中的用户特点值替换提示词中的{用户特点},输入话题块中的所有知识具体信息替换{对话信息},然后输入大模型,得到用户新的对话知识和用户特点。

[0246] 假设长记忆的最大存储限制设置为2,新总结了1条知识,并加入了用户知识信息队列尾部,则将用户知识信息队列头部第1条知识元素删除。

[0247] 参见图9,示出了本发明一个实施例提供的一种AI智能体的记忆系统的检索方法,该检索方法包括以下步骤:

[0248] 步骤1',将用户问询文本作为键,在所述时限查询缓存模块中检索,如果命中,则输出对应的回答文本,并更新所述时限查询缓存模块中相应的键值对的有效时间。

[0249] 可理解的是,对记忆系统的检索方法主要流程如图10所示。用户输入问询文本,首先将问询文本输入时限查询缓存模块,如果命中,则直接输出缓存的记忆,并更新时限查询缓存模块中键值对。如果没有命中,则分别对短期记忆模块、中期记忆模块和长期记忆模块进行检索,然后将检索到的三种记忆拼接并输出,并更新时限查询缓存模块中键值对。

[0250] 其中,基于用户问询文本在时限查询缓存模块中进行检索具体包括:

[0251] 将用户问询文本与时限查询缓存模块中所有的键比对,如果有命中的键,且键值对仍在有效期内,则返回对应的值,并将此键值对的有效时间重新刷新,比如,次键值对的剩余有效时间为100s,如果被命中后,将该键值对的有效时间刷新为3600s;如果没有命中,

则继续检索。

[0252] 如:输入问询:[“不好”]

[0253] 时限查询缓存模块中保存有

[0254] 键值对:[“不好”,“短期记忆,中期记忆,长期记忆”],有效时限:1200秒

[0255] 命中键,且还在有效期内,返回值“短期记忆,中期记忆,长期记忆”

[0256] 如果命中键,但有效时限为0,则返回空值;

[0257] 如果没有命中键,则返回空值。

[0258] 步骤2',如果在所述时限查询缓存模块中未命中,则基于所述用户问询文本分别在所述短期记忆模块、所述中期记忆模块和所述长期记忆模块中进行检索,将得到的短期记忆检索结果、中期记忆检索结果和长期记忆检索结果进行拼接输出,得到检索结果,且根据检索结果更新所述时限查询缓存模块中的键值对。

[0259] 在本发明的一些实施例中,所述基于所述用户问询文本分别在所述短期记忆模块、所述中期记忆模块和所述长期记忆模块中进行检索,包括:

[0260] 步骤21',将用户问询文本输入所述短期记忆模块,所述短期记忆模块直接返回所有问答对最为短期记忆检索结果。

[0261] 可理解的是,对于短期记忆模块的检索,为了获取用户问询文本的上下文情景,直接返回短期记忆模块中的所有问答对。

[0262] 如:

[0263] 短期记忆中有

[0264] 问答对1:[不好][不要也要开心啊]

[0265] 问答对2:[“你好”,“请问有什么可以帮您”]

[0266] 则直接将问答对1和问答对2输出。

[0267] 步骤22',将用户问询文本输入所述中期记忆模块进行检索,分别输出向量召回结果和关键词召回结果,根据所述向量召回结果和所述关键词召回结果,确定中期记忆检索结果。

[0268] 可理解的是,中期记忆模块检索主要包括2个部分,召回和重排序,召回分为向量召回和关键词召回。

[0269] 向量召回:将用户问询文本输入向量嵌入模型,得到问询向量(能够表征此问询的语义),从所述中期记忆模块中召回所有话题块的话题向量;计算所述问询向量与每一个话题块的话题向量之间的余弦相似度,根据所述相似度值,对每一个话题块从高到低进行排序,作为向量召回排序;

[0270] 关键词召回:将用户问询文本与所述中期记忆模块中的每一个话题块的多个关键词进行对比,如果关键词包含在用户问询文本中,则关键词命中,统计每一个话题块中关键词的命中数量;根据每一个话题块中的关键词的命中数量,从多到少对每一个话题块进行排序,作为关键词召回排序;

[0271] 重排序:根据所述向量召回排序和所述关键词召回排序,计算每一个话题块的融合分数:

[0272]
$$rrf-score(d \in D) = \sum_{r \in R} \frac{1}{k + w_r \cdot r(d)};$$

[0273] 其中, rrf-score 表示话题块的融合分数, $r(d)$ 表示话题块 d 在第 r 种召回中的排名, $r=1, 2, k$ 为设定数值, w_r 是第 r 种召回的权重;

[0274] 将融合分数最高的话题块作为检索命中的话题块, 且返回话题块中的话题对话信息, 作为中期记忆检索结果返回。

[0275] 将返回的话题块的属性中的话题频率增加1, 话题最近检索时间刷新为当下时间。

[0276] 如:

[0277] 假设有3个话题块, k 设置为0.001, 关键字召回权重为0.4, 向量召回权重为0.6。对于问询文本 a ,

[0278] 话题块1: 关键字命中2, 向量相似度0.7;

[0279] 话题块2: 关键字命中1, 向量相似度0.9

[0280] 话题块3: 关键字命中0, 向量相似度0.3

[0281] 关键字召回排名: 话题块1, 话题块2, 话题块3

[0282] 向量召回排名: 话题块2, 话题块1, 话题块3

[0283] 话题块1的融合分数为: $0.4 * 1/(0.001+1) + 0.6 * 1/(0.001+2) = 0.699$

[0284] 话题块2的融合分数为: $0.4 * 1/(0.001+2) + 0.6 * 1/(0.001+1) = 0.799$

[0285] 话题块3的融合分数为: $0.4 * 1/(0.001+3) + 0.6 * 1/(0.001+3) = 0.333$

[0286] 话题块2的分数最高, 因此返回话题块2的信息。

[0287] 步骤23', 将用户问询文本输入向量嵌入模型中, 得到问询向量, 计算所述问询向量与所述长期记忆模块中的用户块的每一个知识向量之间的余弦相似度, 返回与所述问询向量的相似度最大的知识向量, 以及从所述长期记忆模块中直接返回用户特点信息, 将返回的用户特点信息和知识信息作为长期记忆检索结果。

[0288] 可理解的是, 对于长期记忆模块的检索, 将问询文本输入向量嵌入模型, 得到问询向量, 向量能够表征此问询的语义。

[0289] 根据输入的用户问询文本的用户ID, 长期记忆模块直接返回用户特点信息。

[0290] 对于用户知识信息: 计算问询向量与长期记忆模块中用户块的每个知识向量的余弦相似度, 返回大于阈值的 (比如阈值设为0.7) 知识具体信息。

[0291] 将分别从短期记忆模块、中期记忆模块和长期记忆模块中检索到的结果进行拼接, 作为最终检索结果返回。拼接在一起的格式为:

[0292] **【短期记忆】**

[0293] {短期记忆}

[0294] **【中期记忆】**

[0295] {中期记忆}

[0296] **【长期记忆】**

[0297] {长期记忆}

[0298] 其中, {短期记忆} 填入的是短期记忆检索结果, {中期记忆} 填入的是中期记忆检索结果, {长期记忆} 填入的是长期记忆检索结果。

[0299] 同时创建键值对, 键为问询文本, 值为记忆检索结果 (拼接后的记忆检索结果), 并添加有效时限 (比如3600秒), 加入时限查询缓存模块。

[0300] 本发明实施例提供的一种AI智能体的记忆系统及其更新方法、检索方法, 具有以

下优点:

[0301] (1)时限查询缓存模块的优点:对于在一定时限范围内几乎完全相同的问询,通过时限查询模块能够直接返回相关记忆,避免问询进入记忆查询流程,极大的提高了记忆检索速度。

[0302] (2)问询质量检测流程的优点:对于重复问答对直接过滤,避免重复问答对进入记忆更新流程,降低了记忆中的重复知识,从而避免记忆质量的下降,也提高了添加记忆的效率。而且对于幻觉回答的纠正(如智能体没能从知识库中搜到相关内容,瞎给的答案),降低了低质量问答对记忆影响。

[0303] (3)短期记忆为:直接为上下文原生文本,中期记忆为:选择产生时间稍早的问答中与本次问询相关的原生文本,长期记忆为:用户的偏好画像和产生时间较早的问答的提炼总结。通过这种方式,能够在有限的上下问词元个数限制下,最大化的提供有用的信息,使得智能体能够更好的完成相应的任务。

[0304] 需要说明的是,在上述实施例中,对各个实施例的描述都各有侧重,某个实施例中沒有详细描述的部分,可以参见其它实施例的相关描述。

[0305] 本领域内的技术人员应明白,本发明的实施例可提供为方法、系统、或计算机程序产品。因此,本发明可采用完全硬件实施例、完全软件实施例、或结合软件和硬件方面的实施例的形式。而且,本发明可采用在一个或多个其中包含有计算机可用程序代码的计算机可用存储介质(包括但不限于磁盘存储器、CD-ROM、光学存储器等)上实施的计算机程序产品的形式。

[0306] 本发明是参照根据本发明实施例的方法、设备(系统)、和计算机程序产品的流程图和/或方框图来描述。应理解可由计算机程序指令实现流程图和/或方框图中的每一流程和/或方框、以及流程图和/或方框图中的流程和/或方框的结合。可提供这些计算机程序指令到通用计算机、专用计算机、嵌入式计算机或者其他可编程数据处理设备的处理器以产生一个机器,使得通过计算机或其他可编程数据处理设备的处理器执行的指令产生用于实现在流程图一个流程或多个流程和/或方框图一个方框或多个方框中指定的功能的装置。

[0307] 这些计算机程序指令也可存储在能引导计算机或其他可编程数据处理设备以特定方式工作的计算机可读存储器中,使得存储在该计算机可读存储器中的指令产生包括指令装置的制造品,该指令装置实现在流程图一个流程或多个流程和/或方框图一个方框或多个方框中指定的功能。

[0308] 这些计算机程序指令也可装载到计算机或其他可编程数据处理设备上,使得在计算机或其他可编程设备上执行一系列操作步骤以产生计算机实现的处理,从而在计算机或其他可编程设备上执行的指令提供用于实现在流程图一个流程或多个流程和/或方框图一个方框或多个方框中指定的功能的步骤。

[0309] 尽管已描述了本发明的优选实施例,但本领域内的技术人员一旦得知了基本创造概念,则可对这些实施例作出另外的变更和修改。所以,所附权利要求意欲解释为包括优选实施例以及落入本发明范围的所有变更和修改。

[0310] 显然,本领域的技术人员可以对本发明进行各种改动和变型而不脱离本发明的精神和范围。这样,倘若本发明的这些修改和变型属于本发明权利要求及其等同技术的范围之内,则本发明也意图包括这些改动和变型在内。



图1

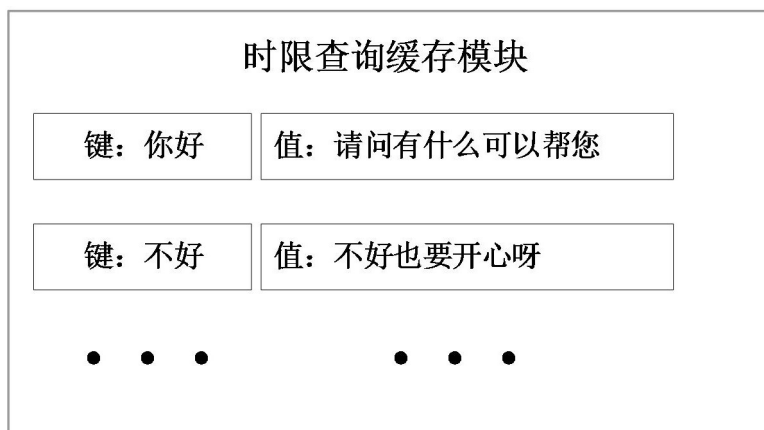


图2




图3




图4




图5




图6




图7




图8

步骤1', 将用户问询文本作为键, 在所述时限查询缓存模块中检索, 如果命中, 则输出对应的回答文本, 并更新所述时限查询缓存模块中相应的键值对的有效时间

步骤2', 如果在所述时限查询缓存模块中未命中, 则基于所述用户问询文本分别在所述短期记忆模块、所述中期记忆模块和所述长期记忆模块中进行检索, 将得到的短期记忆检索结果、中期记忆检索结果和长期记忆检索结果进行拼接输出, 得到检索结果, 且根据检索结果更新所述时限查询缓存模块中的键值对

图9




图10