



(12) 发明专利申请

(10) 申请公布号 CN 120656110 A

(43) 申请公布日 2025. 09. 16

(21) 申请号 202511164753.0

(22) 申请日 2025.08.20

(71) 申请人 湖南大学

地址 410082 湖南省长沙市岳麓区麓山南路麓山门湖南大学

(72) 发明人 张辉 吴读桑 曹意宏 杜瑞
别克扎提·巴合提 刘航 王耀南
毛建旭

(74) 专利代理机构 湖南盈奥知识产权代理事务
所(普通合伙) 43282

专利代理师 龚燕妮 姚瑶

(51) Int. Cl.

G06V 20/40 (2022.01)

G06V 10/30 (2022.01)

G06V 10/62 (2022.01)

G06V 10/80 (2022.01)

G06V 10/82 (2022.01)

G06V 40/20 (2022.01)

G06N 3/045 (2023.01)

G06N 3/0464 (2023.01)


权利要求书2页 说明书10页 附图3页

(54) 发明名称

基于差分梯度进行关键帧增强的视频理解方法及系统

(57) 摘要

本发明公开了一种基于差分梯度进行关键帧增强的视频理解方法及系统,该方法包括步骤1:构建行为识别数据集;步骤2:对行为发生原始视频进行预处理;步骤3:时空梯度注意力运动增强;步骤4:将经过时空梯度注意力运动增强处理后的数据处理后,再进行时空平均池化和线性映射处理,实现对视频中包含的行为进行理解。将视频的差分梯度信息直接参与注意力权重的计算,能够得到符合人类直觉的注意力信息。由生成的注意力权重对空间维度信息进行动态调整,实现像素级的仿射变换,既保持了时序一致性,又能针对不同区域实施差异化处理,在计算效率和增强效果之间取得了显著优于传统方法的平衡。



1. 一种基于差分梯度进行关键帧增强的视频理解方法,其特征在于,包括:

步骤1:构建行为识别数据集;

行为识别数据集包括行为发生原始视频以及行为标签;

步骤2:对行为发生原始视频进行预处理,再将经过预处理后的视频通过PyTorch的Dataset与DataLoader 组件并行读取张量与对应的行为类别标签,所述预处理包括帧抽取和空间变换;

步骤3:时空梯度注意力运动增强;

经过预处理后的张量依次进行差分特征提取和高斯梯度增强处理,以及将经过预处理后的张量进行空间信息池化处理,将经过高斯梯度增强和空间信息池化处理后的结果一起进行时序融合处理,实现时空梯度注意力运动增强;

步骤4:将经过时空梯度注意力运动增强处理后的数据依次进行3D批次分块、连续四个线性编码与Video Swin Transformer串联块处理后,再进行时空平均池化和线性映射处理,实现对视频中包含的行为进行理解。

2. 根据权利要求1所述的方法,其特征在于,所述预处理中帧抽取是从每段视频中均匀采样固定长度为64帧的帧序列;

空间变换是对每帧图像进行中心裁剪或随机裁剪,并对裁剪后的图像分辨率缩放为统一的 224×224 大小。

3. 根据权利要求1所述的方法,其特征在于,所述差分特征提取处理过程如下:

首先,对经过预处理后的张量 $X \in R^{B \times C \times T \times H \times W}$ 计算相邻帧之间的绝对差分;

接着,通过两层小核提取初步的时序变动特征,得到帧间差分信息作为差分特征;

帧间差分信息采用 $X_{dt} \in R^{B \times C \times T \times 1 \times 1}$ 表示;

其中,每一层小核依次包括核3D卷积、组归一化以及GELU处理,组归一化指Group Normalization,通过将通道划分为若干组并在每组内部计算均值和方差进行标准化;GELU是一种平滑的激活函数的高斯误差线性单元。

4. 根据权利要求3所述的方法,其特征在于,所述高斯梯度增强处理过程如下:

首先,将差分特征经过高斯核平滑处理得到平滑帧间差分信息 $X_{dts} \in R^{B \times C \times T \times 1 \times 1}$;

接着,通过有限差分计算梯度,即使用前向、中心、后向差分算子计算平滑帧间差分信息的梯度;

最后,利用归一化函数对平滑帧间差分信息的梯度进行归一化处理,得到平滑帧间梯度信息 $X_g \in R^{B \times C \times T \times 1 \times 1}$ 。

5. 根据权利要求1所述的方法,其特征在于,所述时序融合的处理过程如下:

首先,将原始时域信息经过键生成卷积处理得到用于注意力计算的键向量;以及将平滑帧间梯度信息经过查询生成卷积处理得到用于注意力计算的查询向量;

其次,将原始时域信息和平滑帧间梯度信息进行通道维度拼接后,经过值生成卷积处理得到用于注意力计算的值向量;

最后,将查询向量与键向量相乘后,再进行归一化函数处理,将经过归一化函数处理后的结果与值向量相乘,得到时序融合注意力权重,对平滑帧间梯度信息和时序融合注意力权重进行时序融合。

6. 根据权利要求5所述的方法, 其特征在于, 对经过时序融合处理后的数据再进行基于动态参数的时空调制, 具体过程如下:

首先, 将时序融合特征输入参数生成器, 所述参数生成器依次包括3D卷积、组归一化、GELU以及3D卷积处理;

接着, 将参数生成器输出的数据 $X_{m2} \in R^{B \times 2 \times C \times T \times 1 \times 1}$ 在维度上进行平均拆分, 得到两个维度为 $R^{B \times 1 \times C \times T \times 1 \times 1}$ 的原始参数, 再分别通过归一化函数, 得到“调节”参数 $S_{scale} \in R^{B \times C \times T \times 1 \times 1}$ 与“偏移”参数 $\Delta_{shift} \in R^{B \times C \times T \times 1 \times 1}$;

最后, 利用“调节”参数 $S_{scale} \in R^{B \times C \times T \times 1 \times 1}$ 与“偏移”参数 $\Delta_{shift} \in R^{B \times C \times T \times 1 \times 1}$ 对预处理后的张量进行时空调制, 将时空调制后的数据作为时空梯度注意力运动增强处理后的数据;

时空调制公式如下:

$$X_{out} = (1 - |S_{scale}|) + X(1 + |S_{scale}|) + \Delta_{shift},$$

其中, X_{out} 表示时空调制后的数据, X 表示预处理后的张量。

7. 根据权利要求1-6任一项所述的方法, 其特征在于, 重复步骤2-步骤4, 利用交叉熵损失函数与真实标签进行监督学习, 以优化步骤3和步骤4形成的视频理解网络的分类性能。

8. 一种采用权利要求1-7任一项所述的基于差分梯度进行关键帧增强的视频理解方法的系统, 其特征在于, 包括:

行为识别数据集构建模块: 用于获取行为识别数据集, 包括行为发生原始视频, 行为发生时间以及行为标签;

视频预处理与张量读取模块: 对行为发生原始视频进行预处理, 再将经过预处理后的视频通过PyTorch的Dataset与DataLoader组件并行读取张量与对应的行为类别标签, 所述预处理包括帧抽取和空间变换;

时空梯度注意力运动增强模块: 用于将经过预处理后的张量依次进行差分特征提取和高斯梯度增强处理, 以及将经过预处理后的张量进行空间信息池化处理, 将经过高斯梯度增强和空间信息池化处理后的结果一起进行时序融合处理, 实现时空梯度注意力运动增强;

视频理解模块: 用于将经过时空梯度注意力运动增强处理后的数据依次进行3D批次分块、连续四个线性编码与Video Swin Transformer块处理后, 再进行时空平均池化和线性映射处理, 实现对视频中包含的行为进行理解。

9. 一种计算机可读存储介质, 其特征在于: 存储了计算机程序, 所述计算机程序被处理器调用以实现: 权利要求1-7任一项所述方法的步骤。

10. 一种电子终端, 其特征在于: 包括:

一个或多个处理器;

存储了一个或多个计算机程序的存储器;

其中, 所述处理器调用计算机程序以实现:

权利要求1-7任一项所述方法的步骤。

基于差分梯度进行关键帧增强的视频理解方法及系统

技术领域

[0001] 本发明属于视频处理技术领域,具体涉及一种基于差分梯度进行关键帧增强的视频理解方法及系统。

背景技术

[0002] FiLM即Feature-wise Linear Modulation(逐特征线性调制),是一种在视觉处理领域中有着重要应用的技术。FiLM通过条件输入(如语言问题)生成特征级的缩放(γ)和偏移(β)参数,对目标网络(如CNN)的中间特征进行逐通道的线性变换。这种调制方式不依赖复杂的注意力机制或特征拼接,而是通过轻量化的参数动态调整特征分布,显著提升了模型的性能效率和计算效率。FiLM的 γ 和 β 参数由一个独立的生成网络(如GRU或MLP)根据条件输入(如文本问题)动态生成。例如,在视觉推理任务中,语言问题通过GRU编码后生成不同层次的调制参数,逐层作用于视觉特征的残差块中。这种设计实现了语言与视觉信息的深度交互,而非仅在最后阶段融合。同时FiLM层可直接嵌入到现有网络架构(如ResNet)的中间层中,无需改变网络主体结构。实验表明,FiLM对网络架构的鲁棒性强,即使移除批归一化层或调整残差块数量,性能依然稳定。然而,FiLM对静态图像的条件调制仅在通道维度生成全局 γ/β ,无法反映空间位置或时间步的差异,也未考虑帧间时序结构;其条件来源多依赖外部语言或分类向量,难以自适应挖掘内部时空动态特征。

[0003] Stand-alone Inter-Frame Attention (SIFA)模块是一种独立的帧间注意力原语,通过在局部可变形邻域内对相邻帧的特征进行自注意力计算,精准挖掘时序关联并自适应物体变形。SIFA首先对当前帧的每个空间位置构造Query,对下一帧中对应局部区域内的可变形采样点构造Key/Value,然后通过点积生成注意力权重并加权聚合Value,实现跨帧特征增强;同时利用帧间差分生成的运动显著图指导可变形偏移的预测,使注意力计算能够关注高运动区域并适应大变形场景。然而,SIFA仅在下一帧的局部可变形邻域内计算注意力,难以捕获跨越较长时距的全局时序依赖;其差分重标定偏移仍沿用未经平滑的像素差分,采样点易受噪声影响;且每层特征图只执行一次局部注意力,未能在多尺度和多层次上综合时空动态。

[0004] 论文“Learning from Temporal Gradient for Semi-supervised Action Recognition”的主要创新在于将时序梯度(Temporal Gradient, TG)引入到半监督视频动作识别中,作为与RGB同等重要的第二模态,从而更充分地利用视频的运动信息。为此,作者提出了两种多模态特征约束:一是基于TG到RGB的块级密集对齐(block-wise dense alignment)的知识蒸馏策略,以提取精细运动特征;二是跨模态的对比学习(contrastive learning),以保证高层次语义一致性CVF开放获取。该方法在训练阶段利用TG增强学生模型的表示能力,但在推理阶段仅保留RGB网络,不增加额外计算或参数开销。该方法直接将相邻帧像素差分(Temporal Gradient, TG)作为“第二模态”输入,却没有对梯度信号进行平滑或去噪处理,导致梯度噪声较大、表示易受干扰;在推理阶段也未对不同时间步的重要性进行显式加权或注意力计算,因而无法区分关键帧与冗余帧;此外,TG分支与RGB

分支仅通过一致性损失进行松散耦合,未在特征层面充分融合多模态信息。

发明内容

[0005] 本发明针对现有视频增强方法对时域信息利用不充分;现有的空间调制方法缺乏全局空间上下文建模、增强效果局限于局部区域;以及现有时域注意力方法难以捕获帧间长距离依赖的问题,提出了一种时空梯度注意力运动增强模块,将视频的差分梯度信息直接参与注意力权重的计算,能够得到符合人类直觉的注意力信息。并且由生成的注意力权重对空间维度信息进行动态调整,实现像素级的仿射变换,既保持了时序一致性,又能针对不同区域实施差异化处理,在计算效率和增强效果之间取得了显著优于传统方法的平衡。

[0006] 为此,本发明提供如下技术方案:

[0007] 一种基于差分梯度进行关键帧增强的视频理解方法,包括:

[0008] 步骤1:构建行为识别数据集;

[0009] 行为识别数据集包括行为发生原始视频以及行为标签;

[0010] 数据集包括原始视频与行为标签,不对行为发生时间进行任何标注,仅在进行数据集制作时注意不要让行为发生的时刻都出现在视频的同一个位置,避免网络学习到错误的知识;

[0011] 例如,如果行为的发生时刻都出现在视频的中间位置,网络有可能不学习到任何时间与空间信息,粗暴的将所有视频的中间位置认为是动作发生时刻;

[0012] 步骤2:对行为发生原始视频进行预处理,再将经过预处理后的视频通过PyTorch的Dataset与DataLoader组件并行读取张量与对应的行为类别标签,所述预处理包括帧抽取和空间变换;

[0013] 步骤3:时空梯度注意力运动增强;

[0014] 经过预处理后的张量依次进行差分特征提取和高斯梯度增强处理,以及将经过预处理后的张量进行空间信息池化处理,将经过高斯梯度增强和空间信息池化处理后的结果一起进行时序融合处理,实现时空梯度注意力运动增强;

[0015] 步骤4:将经过时空梯度注意力运动增强处理后的数据依次进行3D批次分块、连续四个线性编码与Video Swin Transformer 串联块处理后,再进行时空平均池化和线性映射处理,实现对视频中包含的行为进行理解。

[0016] 进一步地,所述预处理中帧抽取是从每段视频中均匀采样固定长度为64帧的帧序列;

[0017] 空间变换是对每帧图像进行中心裁剪或随机裁剪,并对裁剪后的图像分辨率缩放为统一的 224×224 大小。

[0018] 堆叠成形状为(B, C, T, H, W)的张量,B为批大小,C为3个RGB通道,T为帧数,H×W为图像分辨率。

[0019] 最后使用PyTorch的Dataset与DataLoader组件并行读取张量与对应的视频所包含的行为类别标签;

[0020] 视频的类别,即车辆以及行人的各类行为,包括车辆的行驶与停止等正常行为以及车辆碰撞等异常行为;包括行人的行走等正常行为以及行人拥堵,行人跌倒等异常行为。

[0021] 进一步地,所述差分特征提取处理过程如下:

- [0022] 首先,对经过预处理后的张量 $X \in R^{B \times C \times T \times H \times W}$ 计算相邻帧之间的绝对差分;
- [0023] 接着,通过两层小核提取初步的时序变动特征,得到帧间差分信息作为差分特征;
- [0024] 帧间差分信息采用 $X_{dt} \in R^{B \times C \times T \times 1 \times 1}$ 表示;
- [0025] 其中,每一层小核依次包括核3D卷积、组归一化以及GELU处理,组归一化指Group Normalization,通过将通道划分为若干组并在每组内部计算均值和方差进行标准化;GELU是一种平滑的激活函数的高斯误差线性单元。
- [0026] 进一步地,所述高斯梯度增强处理过程如下:
- [0027] 首先,将差分特征经过高斯核平滑处理得到平滑帧间差分信息 $X_{dts} \in R^{B \times C \times T \times 1 \times 1}$;
- [0028] 接着,通过有限差分计算梯度,即使用前向、中心、后向差分算子计算平滑帧间差分信息的梯度;
- [0029] 最后,利用归一化函数对平滑帧间差分信息的梯度进行归一化处理,得到平滑帧间梯度信息 $X_g \in R^{B \times C \times T \times 1 \times 1}$ 。
- [0030] 进一步地,所述时序融合的处理过程如下:
- [0031] 首先,将原始时域信息经过键生成卷积处理得到用于注意力计算的键向量;以及将平滑帧间梯度信息经过查询生成卷积处理得到用于注意力计算的查询向量;
- [0032] 其次,将原始时域信息和平滑帧间梯度信息进行通道维度拼接后,经过值生成卷积处理得到用于注意力计算的值向量;
- [0033] 最后,将查询向量与键向量相乘后,再进行归一化函数处理,将经过归一化函数处理后的结果与值向量相乘,得到时序融合注意力权重,对平滑帧间梯度信息和时序融合注意力权重进行时序融合。
- [0034] 进一步地,对经过时序融合处理后的数据再进行基于动态参数的时空调制,具体过程如下:
- [0035] 首先,将时序融合特征输入参数生成器,所述参数生成器依次包括3D卷积、组归一化、GELU以及3D卷积处理;
- [0036] 接着,将参数生成器输出的数据 $X_{m2} \in R^{B \times 2 \times C \times T \times 1 \times 1}$ 在维度上进行平均拆分,得到两个维度为 $R^{B \times 1 \times C \times T \times 1 \times 1}$ 的原始参数,再分别通过归一化函数,得到“调节”参数 $S_{scale} \in R^{B \times C \times T \times 1 \times 1}$ 与“偏移”参数 $\Delta_{shift} \in R^{B \times C \times T \times 1 \times 1}$;
- [0037] 最后,利用“调节”参数 $S_{scale} \in R^{B \times C \times T \times 1 \times 1}$ 与“偏移”参数 $\Delta_{shift} \in R^{B \times C \times T \times 1 \times 1}$ 对预处理后的张量进行时空调制,将时空调制后的数据作为时空梯度注意力运动增强处理后的数据;
- [0038] 时空调制公式如下:
- [0039] $X_{out} = (1 - |S_{scale}|) + X(1 + |S_{scale}|) + \Delta_{shift}$,
- [0040] 其中, X_{out} 表示时空调制后的数据, X 表示预处理后的张量。
- [0041] 基于动态参数的时空调制,将视频信息看作许多帧在时域方向的堆叠,在调制之前,时域方向的参数应该较为平均,即每一帧对最终输出的影响是差不多的,经过时空调制之后,在时域方向看,动作发生时刻附近的帧的参数会被放大,最终对输出的影响更大。
- [0042] Video Swin Transformer为现有方法,Video Swin Transformer 是一种专为视

频理解设计的纯 Transformer 骨干网络,该模型通过在时空维度引入移窗(shifted windows)策略,将视频划分为若干固定大小的 3D patch 窗口,仅在窗口内部计算自注意力,且在不同层级交替平移窗口位置,以兼顾局部细粒度特征与跨窗口长程依赖。在每几个注意力块后,模型使用层级化 patch 合并(patch merging)操作,将相邻 $2 \times 2 \times 2$ 的 patch 合并为一个 token,并对通道数进行扩增,以实现逐步下采样与特征升维;

[0043] $X_{out} \in R^{B \times C \times T \times H \times W}$ 随后进入 Video Swin Transformer 网络,

[0044] 首先由批次编码层将其切分为若干大小一致的 3D patch,并映射到高维特征空间;

[0045] 然后依次通过多层批次融合实现时空下采样与通道扩增,每次批次融合都将特征图的空间与时间维度减半并使通道数加倍;

[0046] 随后经过多个阶段的窗口位移阶段,在每个阶段中,交替执行窗口自注意力计算与移动窗口自注意力计算,以在局部窗口内捕获细粒度时空依赖和跨窗口长程依赖。

[0047] 先用一维高斯卷积核对时序特征进行平滑,再用中心差分算子计算梯度,显著降低噪声并提升信号稳定性;随后将归一化后的梯度幅值作为注意力提示,输入到时序融合注意力模块,为不同时间步分配显式权重,突出了关键帧;最后,在注意力计算中同时融合平滑梯度与投影后的 RGB 特征,实现了更丰富的时空交互,超越了单一一致性损失的弱融合策略。

[0048] 进一步地,重复步骤2-步骤4,利用交叉熵损失函数与真实标签进行监督学习,以优化步骤3和步骤4形成的视频理解网络的分类性能。

[0049] 步骤3-步骤4形成的视频理解网络为增加时空梯度注意力运动增强的Video Swin Transformer 网络。

[0050] 第二方面,一种采用上述的基于差分梯度进行关键帧增强的视频理解方法的系统,包括:

[0051] 行为识别数据集构建模块:用于获取行为识别数据集,包括行为发生原始视频,行为发生时间以及行为标签;

[0052] 视频预处理与张量读取模块:对行为发生原始视频进行预处理,再将经过预处理后的视频通过PyTorch 的 Dataset 与 DataLoader 组件并行读取张量与对应的行为类别标签,所述预处理包括帧抽取和空间变换;

[0053] 时空梯度注意力运动增强模块:用于将经过预处理后的张量依次进行差分特征提取和高斯梯度增强处理,以及将经过预处理后的张量进行空间信息池化处理,将经过高斯梯度增强和空间信息池化处理后的结果一起进行时序融合处理,实现时空梯度注意力运动增强;

[0054] 视频理解模块:用于将经过时空梯度注意力运动增强处理后的数据依次进行3D批次分块、连续四个线性编码与Video Swin Transformer 块处理后,再进行时空平均池化和线性映射处理,实现对视频中包含的行为进行理解。

[0055] 第三方面,一种计算机可读存储介质,存储了计算机程序,所述计算机程序被处理器调用以实现:上述基于差分梯度进行关键帧增强的视频理解方法的步骤。

[0056] 第四方面,一种电子终端,包括:

[0057] 一个或多个处理器;

- [0058] 存储了一个或多个计算机程序的存储器；
- [0059] 其中,所述处理器调用计算机程序以实现:
- [0060] 上述基于差分梯度进行关键帧增强的视频理解方法的步骤。
- [0061] 有益效果
- [0062] 与现有方法相比,本发明的优点有:
- [0063] 1.显式利用时域差分梯度信息进行建模
- [0064] 针对现有视频增强方法对时域信息利用不充分,难以精确表征帧间动态细节的问题,本发明技术方案创新性地将帧间差分梯度信息显式引入到时域建模过程中,从而有效捕捉视频中的运动变化。现有方法非显式的利用梯度信息,会导致无法区分关键帧与冗余,丢失了梯度信息的优势。同时现有的非显示利用帧间差分梯度信息的方法没有对梯度信号进行平滑或去噪处理,存在导致梯度噪声较大,表示易受干扰的问题,本发明采用高斯梯度增强模块对噪声进行抑制,精确表征帧间动态细节。
- [0065] 2.根据注意力信息对原始数据进行全局的像素级空间调制。
- [0066] 现有方法 (FiLM) 只能生成通道级别的调制参数,忽略了空间和时间变化不同,导致关键细节增强不足。针对这个问题,本发明提出时空仿射参数生成模块,利用差分梯度引导的注意力图动态产生局部“调节”参数和全局“偏移”参数,对原始帧像素进行全局空间调制,使模型能够自适应地调整特征强度和基线偏差,从而增强关键区域和细节。同时,仅依靠空间维度的信息难以定位运动发生的时刻,无法针对性关注运动特征,本发明将差分梯度信息参与进调制参数的生成,使其能够根据运动特征自适应调整像素权重。
- [0067] 时空仿射参数生成模块,将融合时空注意力权重动态生成“调节”与“偏移”两个参数,分别实现特征重要性差异与基线偏差补偿。“调节”参数负责局部相对调整,突出重要性区域,而“偏移”参数则负责全局绝对调整,将整体的调节参数控制在合理范围内。总的来说,通过注意力权重引导空间调制参数生成,并针对不同区域动态调整增强运动的强度,在物理层面符合视觉认知原理,相比FiLM更适合处理动态场景下的时空不一致问题。
- [0068] 3.对原始时域信息与差分梯度信息进行全局的时域维度注意力计算。
- [0069] 针对SIFA仅在局部可变形邻域内计算注意力,未能全面捕获帧间长距离依赖的问题,本发明通过时序融合注意力模块,在整个时域尺度上同时关联原始帧序列和差分特征,实现信息的全局时域融合。
- [0070] 而本技术方案提出的时序融合注意力模块将完整的时序信息进行注意力操作,得到时域维度独有的注意力信息。由于空间维度和时域维度组织信息的方式不同,因此针对时域维度单独进行注意力计算能够得到更有意义的注意力信息。同时将原始输入的时域信息与差分梯度信息均进行高斯平滑,避免噪声影响。同时将二者在通道维度进行拼接,作为值向量进行注意力计算,可让注意力机制既关注“何处”有重要内容,又能捕捉“何时”发生显著变化,从而获得更丰富的特征表达,显著提升模型对时序变化敏感性的捕捉和上下文信息的融合效果。

附图说明

- [0071] 图1是本发明技术方案中的时空梯度注意力运动增强模块示意图;
- [0072] 图2是本发明技术方案中的时序融合注意力模块示意图;

- [0073] 图3是本发明技术方案中的差分特征提取模块示意图；
[0074] 图4是本发明技术方案中的高斯梯度增强模块示意图；
[0075] 图5是本发明技术方案中的时空仿射参数生成模块示意图；
[0076] 图6是本发明技术方案中的整体网络结构示意图。

具体实施方式

- [0077] 下面将结合实施例对本发明做进一步的说明。
- [0078] 实施例1：
- [0079] 一种基于差分梯度进行关键帧增强的视频理解方法，包括：
- [0080] 步骤1：构建行为识别数据集；
- [0081] 行为识别数据集包括行为发生原始视频以及行为标签；
- [0082] 行为识别数据集不对行为发生时间进行任何标注，仅在进行数据集制作时注意不要让行为发生的时刻都出现在视频的同一个位置，避免网络学习到错误的知识；
- [0083] 例如，如果行为的发生时刻都出现在视频的中间位置，网络有可能不学习到任何时间与空间信息，粗暴的将所有视频的中间位置认为是动作发生时刻；
- [0084] 从公开数据集（如 Kinetics-400、UCF-101、HMDB51）或自定义摄像头收集大量原始视频，确保涵盖多样化的动作类别。采集各类环境中行人的视频数据，将单个数据的持续时长控制在3~5秒的长度范围，并注意将动作发生的时刻定位在单个视频数据的随机位置。对每段视频按照预定义的动作标签进行标注，形成（video_path, label）对，并存入数据库或 CSV 文件。
- [0085] 步骤2：对行为发生原始视频进行预处理，再将经过预处理后的视频通过PyTorch的 Dataset 与 DataLoader 组件并行读取张量与对应的行为类别标签，所述预处理包括帧抽取和空间变换；
- [0086] 所述预处理中帧抽取是从每段视频中均匀采样固定长度为64帧的帧序列；
- [0087] 空间变换是对每帧图像进行中心裁剪或随机裁剪，并对裁剪后的图像分辨率缩放为统一的 224×224 大小。
- [0088] 堆叠成形状为（B, C, T, H, W）的张量，B为批大小，C为3个RGB通道，T为帧数， $H \times W$ 为图像分辨率。
- [0089] 最后使用PyTorch的 Dataset 与 DataLoader 组件并行读取张量与对应的视频所包含的行为类别标签；
- [0090] 视频的类别，即车辆以及行人的各类行为，包括车辆的行驶与停止等正常行为以及车辆碰撞等异常行为；包括行人的行走等正常行为以及行人拥堵，行人跌倒等异常行为。
- [0091] 步骤3：时空梯度注意力运动增强，如图1所示；
- [0092] 经过预处理后的张量依次进行差分特征提取和高斯梯度增强处理，以及将经过预处理后的张量进行空间信息池化处理，将经过高斯梯度增强和空间信息池化处理后的结果一起进行时序融合处理，实现时空梯度注意力运动增强；
- [0093] 如图3所示，所述差分特征提取处理过程如下：
- [0094] 首先，对经过预处理后的张量 $X \in R^{B \times C \times T \times H \times W}$ 计算相邻帧之间的绝对差分；
- [0095] 接着，通过两层小核提取初步的时序变动特征，得到帧间差分信息作为差分特征；

[0096] 帧间差分信息采用 $X_{dt} \in R^{B \times C \times T \times 1 \times 1}$ 表示;

[0097] 其中,每一层小核依次包括核3D卷积、组归一化以及GELU处理,组归一化指Group Normalization,通过将通道划分为若干组并在每组内部计算均值和方差进行标准化;GELU是一种平滑的激活函数的高斯误差线性单元。

[0098] 如图4所示,所述高斯梯度增强处理过程如下:

[0099] 首先,将差分特征经过高斯核平滑处理得到平滑帧间差分信息 $X_{dts} \in R^{B \times C \times T \times 1 \times 1}$;

[0100] 接着,通过有限差分计算梯度,即使用前向、中心、后向差分算子计算平滑帧间差分信息的梯度;

[0101] 最后,利用归一化函数对平滑帧间差分信息的梯度进行归一化处理,得到平滑帧间梯度信息 $X_g \in R^{B \times C \times T \times 1 \times 1}$ 。

[0102] 如图2所示,所述时序融合的处理过程如下:

[0103] 首先,将原始时域信息经过键生成卷积处理得到用于注意力计算的键向量;以及将平滑帧间梯度信息经过查询生成卷积处理得到用于注意力计算的查询向量;

[0104] 其次,将原始时域信息和平滑帧间梯度信息进行通道维度拼接后,经过值生成卷积处理得到用于注意力计算的键向量;

[0105] 最后,将查询向量与键向量相乘后,再进行归一化函数处理,将经过归一化函数处理后的结果与值向量相乘,得到时序融合注意力权重,对平滑帧间梯度信息和时序融合注意力权重进行时序融合。

[0106] X_m 和 X_g 的维度为 $B \times C \times T \times 1 \times 1$,将 X_m 和 X_g 在批次维度B之后堆叠,生成维度为 $B \times 2 \times C \times T \times 1 \times 1$ 的参数 $X_{m1} \in R^{B \times 2 \times C \times T \times 1 \times 1}$ 。

[0107] 对经过时序融合处理后的数据再进行基于动态参数的时空调制,如图5所示,具体过程如下:

[0108] 首先,将时序融合特征输入参数生成器,所述参数生成器依次包括3D卷积、组归一化、GELU以及3D卷积处理;

[0109] 接着,将参数生成器输出的数据 $X_{m2} \in R^{B \times 2 \times C \times T \times 1 \times 1}$ 在维度上进行平均拆分,得到两个维度为 $R^{B \times 1 \times C \times T \times 1 \times 1}$ 的原始参数,再分别通过归一化函数,得到“调节”参数 $S_{scale} \in R^{B \times C \times T \times 1 \times 1}$ 与“偏移”参数 $\Delta_{shift} \in R^{B \times C \times T \times 1 \times 1}$;

[0110] 最后,利用“调节”参数 $S_{scale} \in R^{B \times C \times T \times 1 \times 1}$ 与“偏移”参数 $\Delta_{shift} \in R^{B \times C \times T \times 1 \times 1}$ 对预处理后的张量进行时空调制,将时空调制后的数据作为时空梯度注意力运动增强处理后的数据;

[0111] 时空调制公式如下:

[0112] $X_{out} = (1 - |S_{scale}|) + X(1 + |S_{scale}|) + \Delta_{shift}$,

[0113] 其中, X_{out} 表示时空调制后的数据, X 表示预处理后的张量。

[0114] 基于动态参数的时空调制,将视频信息看作许多帧在时域方向的堆叠,在调制之前,时域方向的参数应该较为平均,即每一帧对最终输出的影响是差不多的,经过时空调制之后,在时域方向看,动作发生时刻附近的帧的参数会被放大,最终对输出的影响更大。

[0115] Video Swin Transformer为现有方法,Video Swin Transformer 是一种专为视

频理解设计的纯 Transformer 骨干网络,该模型通过在时空维度引入移窗(shifted windows)策略,将视频划分为若干固定大小的 3D patch 窗口,仅在窗口内部计算自注意力,且在不同层级交替平移窗口位置,以兼顾局部细粒度特征与跨窗口长程依赖。在每几个注意力块后,模型使用层级化 patch 合并(patch merging)操作,将相邻 $2 \times 2 \times 2$ 的 patch 合并为一个 token,并对通道数进行扩增,以实现逐步下采样与特征升维。

[0116] $X_{out} \in R^{B \times C \times T \times H \times W}$ 随后进入 Video Swin Transformer 网络:

[0117] 首先由批次编码层将其切分为若干大小一致的 3D patch,并映射到高维特征空间;

[0118] 然后依次通过多层批次融合实现时空下采样与通道扩增,每次批次融合都将特征图的空间与时间维度减半并使通道数加倍;

[0119] 随后经过多个阶段的窗口位移阶段,在每个阶段中,交替执行窗口自注意力计算与移动窗口自注意力计算,以在局部窗口内捕获细粒度时空依赖和跨窗口长程依赖。

[0120] 步骤4:将经过时空梯度注意力运动增强处理后的数据依次进行3D批次分块、连续四个线性编码与Video Swin Transformer 串联块处理后,再进行时空平均池化和线性映射处理,得到对视频中所包含的动作类别预测,实现对视频中包含的行为进行理解。

[0121] 重复步骤2-步骤4,利用交叉熵损失函数与真实标签进行监督学习,以优化步骤3和步骤4形成的如图6所示的视频理解网络的分类性能。

[0122] 步骤3-步骤4形成的视频理解网络为增加时空梯度注意力运动增强的Video Swin Transformer 网络。

[0123] 传统的帧间差分方法通常只计算邻帧像素或特征的简单差值,往往得到二值或噪声较多的运动掩码,缺乏对运动强度的连续量化,从而难以在复杂场景中区分微弱运动与背景变化。相比之下,本发明技术方案首先对帧差特征进行高斯平滑并计算中心差分梯度,然后对绝对梯度值施行 softmax 归一化,生成了一个细腻的运动强度分布,能够更精确地捕获不同帧之间的微小变化。将该梯度分布用作注意力机制中的 Query 后,模型能够根据运动强度动态分配注意力权重,有效突出突发运动事件并抑制无意义的背景变化,从而在时序一致性和空间目标定位上相较于仅依赖二值差分或传统光流输入取得更优表现

[0124] 在传统的时域自注意力机制中,Query、Key 和 Value 均源自同一原始时域特征,注意力分布倾向平均分配,难以主动偏向运动丰富的帧,从而稀释了对动作关键信息的关注度。我们的方法将归一化后的梯度特征作为 Query,以“询问”哪里在运动;将原始时域特征作为 Key,提供全局上下文定位;并将两者拼接后通过卷积生成 Value,使输出同时兼具静态语义与动态提示。这种 Q/K/V 分离设计使注意力矩阵在时间维度上更加“尖锐”,能够将更高的权重集中于运动帧。

[0125] 本发明技术方案通过参数生成网络输出与特征图分辨率相同的 scale 和 shift 参数,以对特征进行像素级仿射变换,从而根据运动驱动的注意力权重对各位置的特征进行放大或偏移。这种基于梯度注意力的像素级调制能够自动引导网络将更多的计算资源集中于运动发生的位置,有效抑制静止背景的干扰,相比依赖额外光流或区域检测的运动引导方法更为轻量且端到端可训练。

[0126] 实施例2

[0127] 一种采用上述的基于差分梯度进行关键帧增强的视频理解方法的系统,包括:

[0128] 行为识别数据集构建模块:用于获取行为识别数据集,包括行为发生原始视频,行为发生时间以及行为标签;

[0129] 视频预处理与张量读取模块:对行为发生原始视频进行预处理,再将经过预处理后的视频通过PyTorch 的 Dataset 与 DataLoader 组件并行读取张量与对应的行为类别标签,所述预处理包括帧抽取和空间变换;

[0130] 时空梯度注意力运动增强模块:用于将经过预处理后的张量依次进行差分特征提取和高斯梯度增强处理,同时,将经过预处理后的张量进行空间信息池化处理,将经过高斯梯度增强和空间信息池化处理后的结果一起进行时序融合处理,实现时空梯度注意力运动增强;

[0131] 视频理解模块:用于将经过时空梯度注意力运动增强处理后的数据依次进行3D批次分块、连续四个线性编码与Video Swin Transformer 块处理后,再进行时空平均池化和线性映射处理,实现对视频中包含的行为进行理解。

[0132] 还应当理解,各个模块的具体实现过程请参照上述方法内容,本发明在此不再赘述,且上述功能模块的划分仅仅为举例说明,在一些实施例中部分功能模块可以合并,部分功能模块可以拆分,各个功能模块可以以软件方式实现或硬件或软硬件结合,其中,软硬件设备包括但不限于通用计算机设备、可编程门阵列、数字信号处理器、微处理器与其相应的编程或烧录软件。

[0133] 实施例3

[0134] 一种计算机可读存储介质,存储了计算机程序,所述计算机程序被处理器调用以实现:上述基于差分梯度进行关键帧增强的视频理解方法的步骤。

[0135] 各个步骤的具体实现过程请参照前述方法的阐述。

[0136] 所述可读存储介质为计算机可读存储介质,其可以是前述任一实施例所述的软硬件设备的内部存储单元,例如控制器的硬盘或内存。所述可读存储介质也可以是所述控制器的外部存储设备,例如所述控制器上配备的插接式硬盘,智能存储卡(Smart Media Card,SMC),安全数字(Secure Digital,SD)卡,闪存卡(Flash Card)等。进一步地,所述可读存储介质还可以既包括所述控制器的内部存储单元也包括外部存储设备。所述可读存储介质用于存储所述计算机程序以及所述控制器所需的其他程序和数据。所述可读存储介质还可以用于暂时地存储已经输出或者将要输出的数据。

[0137] 实施例4

[0138] 一种电子终端,包括:

[0139] 一个或多个处理器;

[0140] 存储了一个或多个计算机程序的存储器;

[0141] 其中,所述处理器调用计算机程序以实现:

[0142] 上述基于差分梯度进行关键帧增强的视频理解方法的步骤。

[0143] 各个步骤的具体实现过程请参照前述方法的阐述。

[0144] 应当理解,在本发明实施例中,所称处理器可以是中央处理单元(Central Processing Unit,CPU),该处理器还可以是其他通用处理器、数字信号处理器(Digital Signal Processor,DSP)、专用集成电路(Application Specific Integrated Circuit,ASIC)、现成可编程门阵列(Field-Programmable Gate Array,FPGA)或者其他可编程逻辑

器件、分立门或者晶体管逻辑器件、分立硬件组件等。通用处理器可以是微处理器或者该处理器也可以是任何常规的处理器等。存储器可以包括只读存储器和随机存取存储器,并向处理器提供指令和数据。存储器的一部分还可以包括非易失性随机存取存储器。例如,存储器还可以存储设备类型的信息。

[0145] 基于这样的理解,本发明的技术方案本质上或者说对现有技术做出贡献的部分,或者该技术方案的全部或部分可以以软件产品的形式体现出来,该计算机软件产品存储在一个存储介质中,包括若干指令用以使得一台计算机设备(可以是个人计算机,服务器,或者网络设备等)执行本发明各个实施例所述方法的全部或部分步骤。而前述的可读存储介质包括:U盘、移动硬盘、只读存储器(ROM, Read-Only Memory)、随机存取存储器(RAM, Random Access Memory)、磁碟或者光盘等各种可以存储程序代码的介质。

[0146] 本领域内的技术人员应明白,本申请的实施例可提供为方法、系统、或计算机程序产品。因此,本申请可采用完全硬件实施例、完全软件实施例、或结合软件和硬件方面的实施例的形式。而且,本申请可采用在一个或多个其中包含有计算机可用程序代码的计算机可读存储介质(包括但不限于磁盘存储器、CD-ROM、光学存储器等)上实施的计算机程序产品的形式。本申请是参照根据本申请实施例的方法、设备(系统)、和计算机程序产品的流程图和/的处理器执行的指令产生用于实现在流程图的一个流程或多个流程和/或方框图的一个方框或多个方框中指定的功能的装置。这些计算机程序指令也可存储在能引导计算机或其他可编程数据处理设备以特定方式工作的计算机可读存储器中,使得存储在该计算机可读存储器中的指令产生包括指令装置的制造品,该指令装置实现在流程图的一个流程或多个流程和/或方框图的一个方框或多个方框中指定的功能。这些计算机程序指令也可装载到计算机或其他可编程数据处理设备上,使得在计算机或其他可编程设备上执行一系列操作步骤以产生计算机实现的处理,从而在计算机或其他可编程设备上执行的指令提供用于实现在流程图的一个流程或多个流程和/或方框图的一个方框或多个方框中指定的功能的步骤。

[0147] 需要强调的是,本发明所述的实例是说明性的,而不是限定性的,因此本发明不限于具体实施方式中所述的实例,凡是由本领域技术人员根据本发明的技术方案得出的其他实施方式,不脱离本发明宗旨和范围的,不论是修改还是替换,同样属于本发明的保护范围。




图 1




图 2




图 3




图 4




图 5




图 6